

Statystyczne modelowanie tekstu - łańcuchy Markova

Teoria Informacji i Metody Kompresji Danych - laboratorium

Jakub Bilski, 155865, Informatyka (ST), Semestr VI, L6

11 kwietnia 2025

1 Wprowadzenie

Niniejsze sprawozdanie przedstawia wyniki eksperymentów dotyczących statystycznego modelowania tekstu przy użyciu łańcuchów Markova różnych rzędów. Eksperymenty zostały przeprowadzone w ramach laboratorium, a ich celem było zrozumienie, jak różne modele statystyczne wpływają na generację tekstu oraz jakie są ich charakterystyki i ograniczenia.

Statystyczne modelowanie tekstu jest obszarem przetwarzania języka naturalnego, który koncentruje się na budowaniu modeli matematycznych reprezentujących strukturę tekstu. Modele te mogą być wykorzystywane do generowania tekstu, kompresji danych czy rozpoznawania mowy. Łańcuchy Markova, będące głównym przedmiotem badań w tym sprawozdaniu, opierają się na założeniu, że prawdopodobieństwo wystąpienia danego znaku zależy tylko od określonej liczby poprzednich znaków (tzw. rząd łańcucha).

2 Metody badawcze

Badania przeprowadzono przy użyciu języka Python, implementując kolejno coraz bardziej zaawansowane techniki modelowania statystycznego:

1. Przybliżenie zerowego rzędu - generowanie znaków z równym prawdopodobieństwem.
2. Analiza częstości znaków - badanie rozkładu występowania poszczególnych znaków w tekście.

3. Przybliżenie pierwszego rzędu - generowanie znaków z uwzględnieniem ich częstości w tekście źródłowym.
4. Analiza warunkowych prawdopodobieństw - badanie zależności między sąsiadującymi znakami.
5. Modele Markova różnych rzędów (1, 3, 5) - budowa modeli uwzględniających kontekst o różnej długości.

Jako dane wejściowe wykorzystano plik tekstowy `norm_wiki_sample.txt` zawierający próbkę tekstu z Wikipedii. Dla każdego z badanych modeli wygenerowano teksty o długości 1000 znaków, które następnie zostały poddane analizie pod kątem średniej długości słów i innych charakterystyk.

3 Implementacja

Główne funkcje zaimplementowane w ramach eksperymentów to:

```

1 def generate_random_string(charset, length):
2     return ''.join(random.choice(charset) for _ in range(length))
3
4 def average_length(message):
5     words = message.split()
6     return sum(map(len, words)) / len(words) if words else 0
7
8 def zeroRowApproximation():
9     message = generate_random_string(alphabet, 100000)
10    print('\n rednia d ugo s owa - przybli enie zerowego
    rz du:\n', average_length(message))
11    return message, average_length(message)

```

Listing 1: Funkcje do generacji tekstu metodą zerowego rzędu

```

1 def letter_frequency(content):
2     dictionary = dict.fromkeys(alphabet, 0)
3     for char in content:
4         if char in dictionary:
5             dictionary[char] += 1
6     return dictionary

```

Listing 2: Funkcje do analizy częstości znaków

```

1 def firstRowApproximation(length):
2     freq_dict = letter_frequency(read_file(filename))
3     generated = ''
4     letters = [*freq_dict.keys()]
5     weights = [*freq_dict.values()]

```

```

6     for _ in range(length):
7         generated += random.choices(letters, weights=weights)[0]
8     words = generated.split()
9     if words:
10         total_length = sum(len(word) for word in words)
11         average = total_length / len(words)
12     else:
13         average = 0
14     return generated, average

```

Listing 3: Funkcja dla przybliżenia pierwszego rzędu

```

1 def conditional_probabilities(text, alphabet, letter_freq):
2     most_common = [letter for letter, count in sorted(letter_freq.
3 items(), key=lambda item: item[1], reverse=True)[:2]]
4     print("Najcz ściej wyst puje znaki:", most_common)
5
6     pairs = defaultdict(int)
7     for i in range(len(text) - 1):
8         first, second = text[i], text[i + 1]
9         if first in most_common:
10             pairs[(first, second)] += 1
11
12     conditional_probs = {letter: {} for letter in most_common}
13     for (first, second), count in pairs.items():
14         conditional_probs[first][second] = count / letter_freq[
15 first]
16
17     # Wy wietlanie wynik w
18     for first_letter in most_common:
19         print(f"Warunkowe prawdopodobie stwo dla '{first_letter
20 }':")
21         sorted_probs = sorted(conditional_probs[first_letter].
22 items(), key=lambda item: item[1], reverse=True)
23         for second_letter, prob in sorted_probs:
24             print(f"P({second_letter} | {first_letter}) = {prob:.4
25 f}")
26
27     return conditional_probs

```

Listing 4: Funkcja do obliczania warunkowych prawdopodobieństw

```

1 def markov_approx(text, order, length, start_sequence=None):
2     if order == 0:
3         generated_text = generate_random_string(alphabet, length)
4         return generated_text, average_length(generated_text)
5
6     model = defaultdict(Counter)
7
8     if order == 1:

```

```

9         for i in range(len(text) - 1):
10             current = text[i]
11             next_char = text[i + 1]
12             model[current][next_char] += 1
13     else:
14         for i in range(len(text) - order):
15             context = text[i:i + order]
16             next_char = text[i + order]
17             model[context][next_char] += 1
18
19     probability_model = {}
20
21     for context, counter in model.items():
22         total = sum(counter.values())
23         if total > 0:
24             probability_model[context] = {char: count / total for
25 char, count in counter.items()}
26
27     if not probability_model:
28         return "", 0
29
30     if start_sequence and len(start_sequence) == order:
31         current = start_sequence
32     elif order == 1:
33         current = random.choice(list(probability_model.keys()))
34     else:
35         current = random.choice(list(probability_model.keys()))
36
37     generated_text = current
38
39     for _ in range(length - len(current)):
40         if current not in probability_model:
41             current = random.choice(list(probability_model.keys()))
42         next_chars = list(probability_model[current].keys())
43         next_probs = list(probability_model[current].values())
44
45         next_char = random.choices(next_chars, weights=next_probs)
46         generated_text += next_char[0]
47
48         if order > 1:
49             current = current[1:] + next_char
50         else:
51             current = next_char
52
53     return generated_text, average_length(generated_text)

```

Listing 5: Funkcja do generacji tekstu za pomocą modeli Markova

4 Wyniki i analiza

4.1 Przybliżenie zerowego rzędu

Przybliżenie zerowego rzędu generuje tekst w najprostszy możliwy sposób - znaki są wybierane z jednakowym prawdopodobieństwem, niezależnie od kontekstu. Wyniki pokazują, że:

- Wygenerowany tekst jest całkowicie losowy i przypomina ciąg przypadkowych znaków.
- Średnia długość słów wynosi około 36,11, co jest znacznie powyżej średniej dla języka naturalnego (około 5,1). Ta nienaturalnie wysoka wartość wynika z braku spacji w równomiernym rozkładzie prawdopodobieństwa.
- W tekście brak jest jakichkolwiek zależności między kolejnymi znakami.
- Generowane "słowa" składają się z przypadkowych liter i cyfr, często niemożliwych do wymówienia.

Przykład tekstu wygenerowanego metodą zerowego rzędu

```
zq491x171mjflux      9hvapr      lhnzf3k      5q2uw6fcw7613ruk0w
k4d38gfdtbf65alhoazhtle
dy53ejqnsqzplmehfdaj5lc3scpqbb7ija32887
alhtpkjoyjueifncmvzqwycfnqb10m3h6md9xzj6ekvmiucta0l49zfxey
auc0eaolypsk7xwq9o08cl7rwyf4334cfb      534p8wynsqp      pz58pv15sot
wkmx3blrurcznty
```

4.2 Analiza częstości liter


Analiza częstości występowania poszczególnych znaków w tekście źródłowym dostarcza istotnych informacji o strukturze języka:

- Spacja jest najczęściej występującym znakiem w tekście angielskim (1 840 507 wystąpień), co odzwierciedla strukturę języka składającego się z oddzielnych słów.
- Druga najczęstsza litera to 'e' (1 009 158 wystąpień), co jest zgodne z ogólnymi statystykami dla języka angielskiego.
- Rozkład częstości liter jest nierównomierny - najczęstsze litery ('e', 'a', 't', 'i', 'n', 'o') występują znacznie częściej niż najrzadsze ('q', 'z', 'x').

- Cyfry występują rzadziej niż litery, co jest zgodne z oczekiwaniami dla tekstów w języku naturalnym.
- Ta wiedza stanowi podstawę do bardziej efektywnego kodowania tekstu, np. w kodzie Huffmana.

Fragment wyników analizy częstości znaków

Liczba wystąpień znaków (10 najczęstszych): [(' ', 1840507), ('e', 1009158), ('a', 777876), ('t', 715266), ('i', 657640), ('n', 643628), ('o', 627012), ('r', 586088), ('s', 572689), ('h', 393431), ...]



Rysunek 1: Wizualizacje dla modelowania tekstu: częstość znaków oraz warunkowe prawdopodobieństwa

4.3 Przybliżenie pierwszego rzędu

Przybliżenie pierwszego rzędu uwzględnia częstość występowania poszczególnych znaków w tekście źródłowym, ale nadal nie uwzględnia zależności między znakami:

- Średnia długość słów wynosi około 5,56, co jest bliższe wartości w języku naturalnym.
- Generowany tekst wciąż nie przypomina języka naturalnego, ale rozkład znaków jest bardziej realistyczny.
- Możemy zaobserwować większą liczbę spacji, co powoduje tworzenie większej liczby krótszych "słów".

- Model ten nie uwzględnia zależności między znakami, co jest jego kluczowym ograniczeniem - znaki są wybierane niezależnie od kontekstu.


Przykład tekstu wygenerowanego metodą pierwszego rzędu

tsieeenmyam tnrrsttid dadta toecr ss aisua0h2ehs i rggnteftevr n
ntoeudbgao teianrrl topol ieh 2sone0 npwhacrhtdi nittncma so se3yi
t2hycshiiyret rcaeairala7arito trra t 2si ta rlioegm nsaallaeupeteaiuf
aoantgso oh ttho1t tl ias0alaeak 2

4.4 Warunkowe prawdopodobieństwa

Analiza warunkowych prawdopodobieństw pokazuje, jakie znaki najczęściej występują po określonym znaku:

- Po spacji najczęściej występują litery rozpoczynające słowa w języku angielskim, jak 't', 'a', 'i'.
- Dla innych popularnych liter (np. 'e') występują charakterystyczne wzorce następujących po nich znaków.
- Te warunkowe prawdopodobieństwa są podstawą do budowy modelu Markowa pierwszego rzędu.
- Analiza ta ujawnia charakterystyczne sekwencje liter występujące w języku angielskim.
- Warunkowe prawdopodobieństwa odzwierciedlają reguły fonologiczne i morfologiczne języka.



Rysunek 2: Porównanie warunkowych prawdopodobieństw dla znaków występujących po spacji i po literze 'e'

4.5 Modele Markova różnych rzędów

4.5.1 Model Markova 1-go rzędu

Model Markova pierwszego rzędu uwzględnia warunkowe prawdopodobieństwa między sąsiadującymi znakami:

- Średnia długość słów wynosi około 4,53, co jest nieco niższe niż średnia dla normalnego tekstu.
- Tekst zaczyna zawierać fragmenty przypominające rzeczywiste słowa (np. "the", "and", "we"), choć wciąż jest w większości nieczytelny.
- Pojawiają się kombinacje liter charakterystyczne dla języka angielskiego.
- Wciąż brakuje struktur wyższego rzędu, co prowadzi do braku spójności między słowami.

Przykład tekstu wygenerowanego modelem Markova 1-go rzędu

pr dw ond the twhee itho n tagreduck uxpemtinwathes vin e suns wicecaf
 onede ore a s til thelekesuchisouuttath clavind we rely pry icam fold
 ciprthe d eencthe the d rasedun soua s hiben t ecorarengusiithe s
 heviththened mche d anticonarsong aden 1336

4.5.2 Model Markova 3-go rzędu

Model Markova trzeciego rzędu uwzględnia kontekst trzech poprzednich znaków:

- Średnia długość słów wynosi około 5,18, co jest wyższe niż w modelu pierwszego rzędu i najbardziej zbliżone do normalnej średniej.
- Generowane są całe poprawne słowa i czasami krótkie frazy (np. "was rap in", "the live", "the collow field world").
- Tekst wciąż nie ma sensu semantycznego, ale jest znacznie bardziej czytelny.
- Widoczne są wzorce specyficzne dla języka angielskiego, jak typowe końcówki słów czy kombinacje liter.

Przykład tekstu wygenerowanego modelem Markova 3-go rzędu

t quadesh stotyperst was rap in skin the live 26 m 2012 00 ava tricanal
times the collow field world labelgiulies old clas cords comentiron on s
for the 1882 the bornesis rimagnoship form ricking cording honomine firer
usgrame as a temself bud on inf

4.5.3 Model Markova 5-go rzędu

Model Markova piątego rzędu uwzględnia kontekst pięciu poprzednich znaków:

- Średnia długość słów wynosi około 4,96, co jest dość zbliżone do naturalnej średniej.
- Generowane są realistyczne sekwencje słów, często gramatycznie poprawne (np. "inferior to the disk", "the same year team", "popular dragon").
- W tekście pojawiają się fragmenty, które mogłyby pochodzić z rzeczywistego tekstu angielskiego.
- Uwzględnienie dłuższego kontekstu pozwala na zachowanie pewnych wzorców lingwistycznych i generowanie bardziej sensownych kombinacji słów.

Przykład tekstu wygenerowanego modelem Markova 5-go rzędu

h lolivery of inferior to the disk regional district in the similar to the
weapons the same year team however the producer sound institute correcting
popular dragon az theated for it was marko kovalain is caretaking surface
as that red a bridge and b

4.6 Eksperyment z "probability"

Przeprowadzono dodatkowy eksperyment polegający na generowaniu tekstu rozpoczynającego się od słowa "probability", a dokładniej wykorzystując jego ostatnie 5 znaków ("ility") jako początkowy kontekst dla modelu Markova 5-go rzędu:


- Początkowy kontekst ("ility") wpływa na generowanie dalszego tekstu.
- Eksperyment pokazał, że średnia długość słowa w tym przypadku wyniosła 5,03, co jest bliskie średniej dla naturalnego tekstu.
- Wygenerowany tekst zawiera sensowne frazy jak "met at the allowance of", które mają logiczną strukturę.
- Ta technika pokazuje, jak model statystyczny może "uczyć się" wzorców występujących w określonym kontekście.

Eksperyment z początkowym słowem "probability"


probability last 6 2007 neodymium met at the allowance of two from different antonio book was the mi

5 Porównanie średnich długości słów

Jednym z kluczowych mierników jakości generowanego tekstu jest średnia długość słów, która dla rzeczywistego języka angielskiego wynosi około 5,1 znaku.



Rysunek 3: Porównanie średniej długości słów dla różnych modeli



Rysunek 4: Wpływ rzędu modelu Markova na średnią długość słów

Jak widać na wykresie, wraz ze wzrostem rzędu modelu Markova, średnia długość słów najpierw rośnie (od modelu 1-go do 3-go rzędu), a następnie nieznacznie spada (między modelem 3-go a 5-go rzędu). Model Markova 3-go rzędu generuje najdłuższe słowa (5,18), co może sugerować, że ten rząd modelu najlepiej uchwytuje strukturę słów w analizowanym tekście.

6 Wnioski

6.1 Wnioski ogólne

Na podstawie przeprowadzonych eksperymentów można sformułować następujące wnioski:

- Wraz ze wzrostem rzędu modelu Markova, generowany tekst staje się coraz bardziej podobny do języka naturalnego.
- Średnia długość słów zwiększa się wraz z rzędem modelu, zbliżając się do wartości charakterystycznej dla analizowanego tekstu źródłowego.
- Wyższe rzędy modelu Markova wymagają więcej danych i obliczeń, ale dają znacznie lepsze rezultaty.
- Modele statystyczne, choć proste, mogą skutecznie uchwycić pewne aspekty struktury języka.

- Żaden z zaprezentowanych modeli nie uwzględnia semantyki - generowany tekst może przypominać język naturalny, ale nie posiada znaczenia.
- Analiza statystyczna tekstu pozwala na zrozumienie pewnych fundamentalnych właściwości języka naturalnego.
- Modele Markova mają praktyczne zastosowania w kompresji danych, rozpoznawaniu mowy i generowaniu tekstu.

6.2 Ograniczenia modeli Markova

Pomimo rosnącej jakości generowanego tekstu wraz ze wzrostem rzędu modelu, modele Markova mają pewne inherentne ograniczenia:

- Nie uwzględniają długodystansowych zależności w tekście.
- Nie rozumieją semantyki ani gramatyki języka.
- Wymagają dużych zbiorów danych treningowych dla wyższych rzędów modelu.
- Efektywność pamięciowa spada wykładniczo wraz ze wzrostem rzędu modelu.
- Nie są w stanie generować semantycznie spójnego tekstu na poziomie akapitów czy dłuższych fragmentów.

7 Podsumowanie

Przeprowadzone eksperymenty pokazują, jak proste modele statystyczne mogą modelować strukturę języka naturalnego. Łańcuchy Markova stanowią interesujące narzędzie do analizy tekstu i, mimo swoich ograniczeń, pozwalają na generowanie tekstu o cechach zbliżonych do języka naturalnego.

Warto zauważyć, że współcześnie modele statystyczne, takie jak łańcuchy Markova, zostały w dużej mierze zastąpione przez modele oparte na sieciach neuronowych, które lepiej radzą sobie z uwzględnianiem długodystansowych zależności w tekście. Niemniej, zrozumienie podstaw statystycznego modelowania tekstu jest wartościowe z perspektywy edukacyjnej i stanowi punkt wyjścia do bardziej zaawansowanych technik przetwarzania języka naturalnego.