

Rozpoznawanie języka naturalnego na podstawie analizy entropii

Jakub Bilski 155865

18 maja 2025

1 Wprowadzenie

Niniejsze sprawozdanie przedstawia metodę rozpoznawania języka naturalnego poprzez analizę entropijną. W podstawie tego podejścia leży obserwacja, że teksty w językach naturalnych charakteryzują się określonymi wzorcami statystycznymi, które można wykryć przy pomocy narzędzi teorii informacji.

Kluczową ideą jest porównanie entropii bezwarunkowej (zerowego rzędu) z entropią warunkową (pierwszego rzędu), co pozwala odróżnić teksty w językach naturalnych od tekstów generowanych losowo. Języki naturalne wykazują wyraźne prawidłowości statystyczne, które sprawiają, że entropia warunkowa jest znacząco niższa niż entropia bezwarunkowa, natomiast w przypadku tekstów losowych obie te wartości są do siebie zbliżone.

2 Podstawy teoretyczne

2.1 Entropia w teorii informacji

Entropia w teorii informacji, wprowadzona przez Claude'a Shannona, jest miarą niepewności lub losowości zmiennej losowej. W kontekście analizy tekstu, entropię można interpretować jako miarę nieprzewidywalności znaków lub słów.

Dla zmiennej losowej X z rozkładem prawdopodobieństwa $p(x)$, entropia $H(X)$ jest zdefiniowana jako:

$$H(X) = - \sum_{x \in X} p(x) \log_2 p(x) \quad (1)$$

Jednostką entropii są bity, co wynika z zastosowania logarytmu o podstawie 2. W implementacji jest to realizowane następująco:

```
1 def char_entropy(text):
2     """Oblicza entropię znak w zerowego rzędu (H0)"""
3     if not text:
4         return 0
5
6     freq = Counter(text)
7     total = sum(freq.values())
8     return -sum((count/total) * math.log2(count/total)
9                 for count in freq.values() if count > 0)
```

2.2 Entropia warunkowa

Entropia warunkowa $H(Y|X)$ mierzy, ile niepewności pozostaje odnośnie do zmiennej Y , gdy znamy wartość zmiennej X . W kontekście analizy tekstu, entropia warunkowa pierwszego rzędu mierzy, jak nieprzewidywalny jest znak, gdy znamy poprzedzający go znak.

Matematycznie entropia warunkowa jest zdefiniowana jako:

$$H(Y|X) = - \sum_{x \in X} p(x) \sum_{y \in Y} p(y|x) \log_2 p(y|x) \quad (2)$$

W implementacji obliczamy entropię warunkową znaków następująco:

```
1 def conditional_char_entropy(text, order=1):
2     """Oblicza entropię warunkową znaków rzędu order"""
3     if len(text) <= order:
4         return 0
5
6     # Zliczamy n-gramy długości order+1 i order
7     ngrams_next = Counter([text[i:i+order+1] for i in range(len(text)-
8         order)])
9     ngrams_curr = Counter([text[i:i+order] for i in range(len(text)-
10         order+1)])
11
12     total_ngrams = sum(ngrams_next.values())
13     entropy = 0
14
15     for ngram_next, count in ngrams_next.items():
16         prefix = ngram_next[:-1]
17         # Obliczamy prawdopodobieństwo warunkowe P(znak|kontekst)
18         prob = count / ngrams_curr[prefix]
19         # Liczymy wkład do entropii warunkowej
20         entropy -= (count / total_ngrams) * math.log2(prob)
21
22     return entropy
```

Powyższy kod realizuje obliczanie entropii warunkowej poprzez zliczanie wystąpień n-gramów i obliczanie prawdopodobieństw warunkowych. Dla entropii warunkowej pierwszego rzędu (`order=1`), zliczamy bigramy (pary znaków) i obliczamy, z jakim prawdopodobieństwem po danym znaku występuje określony następny znak. Dla entropii warunkowej drugiego rzędu (`order=2`), analizujemy, jak dwa poprzednie znaki wpływają na prawdopodobieństwo wystąpienia trzeciego znaku.

2.3 Stosunek entropii jako miara naturalności języka

Kluczowym wskaźnikiem, który pozwala odróżnić języki naturalne od tekstów losowych, jest stosunek entropii warunkowej pierwszego rzędu do entropii bezwarunkowej:

$$R = \frac{H(X_{i+1}|X_i)}{H(X)} \quad (3)$$

W językach naturalnych, ze względu na prawidłowości statystyczne, entropia warunkowa jest znacząco niższa niż entropia bezwarunkowa, co daje wartość R wyraźnie poniżej 1. Dla tekstów losowych, gdzie znajomość poprzedniego znaku nie pomaga w przewidywaniu następnego, wartość R jest bliska 1.

W implementacji obliczamy ten stosunek następująco:

```

1 # Obliczamy stosunek entropii warunkowej do bezwarunkowej
2 if results['char_entropy'] > 0:
3     results['char_ratio_1'] = results['char_cond_entropy_1'] / results['
    char_entropy']
4 else:
5     results['char_ratio_1'] = float('inf')

```

Dlaczego ten stosunek jest niższy dla języków naturalnych? Wynika to z faktu, że w językach naturalnych występują określone prawidłowości, takie jak:

- Częste występowanie określonych kombinacji liter (np. w języku polskim po literze 'c' często występuje 'z' lub 'h')
- Reguły gramatyczne i ortograficzne, które ograniczają możliwe sekwencje znaków
- Struktury morfologiczne (prefiksy, sufiksy, rdzenie), które generują powtarzalne wzorce

Te prawidłowości powodują, że znając poprzedni znak (lub znaki), możemy z większym prawdopodobieństwem przewidzieć następny znak, co zmniejsza entropię warunkową w porównaniu z entropią bezwarunkową.

3 Implementacja

3.1 Przetwarzanie tekstu

Teksty przetwarzane są zgodnie z określonymi zasadami:

- Wszystkie znaki są konwertowane na małe litery
- Zachowywane są tylko znaki z określonego alfabetu (26 małych liter alfabetu łacińskiego, cyfry i spacje)
- Znaki spoza alfabetu, w tym znaki specjalne i litery z akcentami, są pomijane

```

1 def load_text(filename):
2     """Wczytuje tekst z pliku i filtruje znaki do dozwolonego alfabetu
    """
3     try:
4         with open(filename, 'r', encoding='utf-8') as f:
5             text = f.read().lower()
6             # Zostawiamy tylko znaki z naszego alfabetu
7             filtered_text = ''.join(c for c in text if c in ALPHABET)
8             return filtered_text
9     except Exception as e:
10        print(f"Błąd wczytywania pliku {filename}: {e}")
11        return ""

```

Filtrowanie tekstu jest istotnym etapem przygotowania danych. W przypadku języków, które używają znaków spoza podstawowego alfabetu łacińskiego (np. znaki diakrytyczne, litery specyficzne dla danego języka), znaki te są zastępowane ich najbliższymi odpowiednikami w alfabecie łacińskim lub pomijane. Jest to ważne dla zapewnienia porównywalności wyników między różnymi językami, niezależnie od używanego alfabetu.

3.2 Analiza języków referencyjnych

Analizowane są następujące języki referencyjne:

- Angielski (norm_wiki_en.txt)
- Łaciński (norm_wiki_la.txt)
- Esperanto (norm_wiki_eo.txt)
- Estoński (norm_wiki_et.txt)
- Somalijski (norm_wiki_so.txt)
- Haitański (norm_wiki_ht.txt)
- Navaho (norm_wiki_nv.txt)

Wybór tych języków nie jest przypadkowy. Obejmują one różne rodziny językowe i różne systemy językowe, co pozwala na sprawdzenie uniwersalności metody. Angielski jest językiem germańskim, łaciński - językiem romańskim, estoński - językiem ugrofińskim, somalijski - językiem kuszyckiej gałęzi rodziny afroazjatyckiej, haitański - kreolskim opartym na francuskim, a navaho - językiem na-dene. Esperanto jest sztucznym językiem, który jednak zaprojektowano zgodnie z prawidłowościami występującymi w językach naturalnych.

3.3 Klasyfikacja próbek

Klasyfikacja próbek opiera się na porównaniu stosunku entropii warunkowej do bezwarunkowej z ustalonym progiem:

```
1 def is_natural_language(results, threshold=0.8):
2     """Decyduje czy tekst jest j zykiem naturalnym na podstawie prog
    entropii"""
3     # J zyki naturalne maj niski stosunek entropii warunkowej do
    bezwarunkowej
4     return results['char_ratio_1'] < threshold
```

Wartość progowa 0.8 została ustalona na podstawie analizy języków referencyjnych. Jest to wartość, która pozwala skutecznie odróżnić teksty w językach naturalnych od tekstów losowych. Teksty, dla których stosunek entropii warunkowej do bezwarunkowej jest niższy niż 0.8, są klasyfikowane jako języki naturalne, a teksty z wyższym stosunkiem - jako teksty losowe lub sztuczne.

4 Wyniki i analiza

4.1 Analiza języków referencyjnych

Wyniki analizy entropijnej dla wszystkich badanych języków referencyjnych są następujące:

=== Analiza języków referencyjnych ===

Angielski (norm_wiki_en.txt):

Entropia znaków (H0): 4.2882 bitów/znak
Entropia słów (H0): 11.5440 bitów/słowo
Entropia warunkowa znaków (H1): 3.5166 bitów/znak
Entropia warunkowa znaków (H2): 3.0183 bitów/znak
Entropia warunkowa słów (H1): 6.3892 bitów/słowo
Entropia warunkowa słów (H2): 2.1765 bitów/słowo
Stosunek H1/H0 (znaki): 0.8201

Łaciński (norm_wiki_la.txt):

Entropia znaków (H0): 4.2282 bitów/znak
Entropia słów (H0): 11.9692 bitów/słowo
Entropia warunkowa znaków (H1): 3.4501 bitów/znak
Entropia warunkowa znaków (H2): 2.8235 bitów/znak
Entropia warunkowa słów (H1): 4.4000 bitów/słowo
Entropia warunkowa słów (H2): 1.1669 bitów/słowo
Stosunek H1/H0 (znaki): 0.8160

Esperanto (norm_wiki_eo.txt):

Entropia znaków (H0): 4.1768 bitów/znak
Entropia słów (H0): 11.5605 bitów/słowo
Entropia warunkowa znaków (H1): 3.3400 bitów/znak
Entropia warunkowa znaków (H2): 2.8718 bitów/znak
Entropia warunkowa słów (H1): 6.5577 bitów/słowo
Entropia warunkowa słów (H2): 2.4847 bitów/słowo
Stosunek H1/H0 (znaki): 0.7997

Estoński (norm_wiki_et.txt):

Entropia znaków (H0): 4.1698 bitów/znak
Entropia słów (H0): 13.7462 bitów/słowo
Entropia warunkowa znaków (H1): 3.5070 bitów/znak
Entropia warunkowa znaków (H2): 3.1344 bitów/znak
Entropia warunkowa słów (H1): 5.4242 bitów/słowo
Entropia warunkowa słów (H2): 0.9047 bitów/słowo
Stosunek H1/H0 (znaki): 0.8410

Somalijski (norm_wiki_so.txt):

Entropia znaków (H0): 4.0401 bitów/znak
Entropia słów (H0): 11.7311 bitów/słowo
Entropia warunkowa znaków (H1): 3.2996 bitów/znak
Entropia warunkowa znaków (H2): 2.8444 bitów/znak
Entropia warunkowa słów (H1): 5.3987 bitów/słowo
Entropia warunkowa słów (H2): 1.6086 bitów/słowo
Stosunek H1/H0 (znaki): 0.8167

Haitański (norm_wiki_ht.txt):

Entropia znaków (H_0): 4.1464 bitów/znak
Entropia słów (H_0): 8.1669 bitów/słowo
Entropia warunkowa znaków (H_1): 3.1139 bitów/znak
Entropia warunkowa znaków (H_2): 2.2735 bitów/znak
Entropia warunkowa słów (H_1): 3.1931 bitów/słowo
Entropia warunkowa słów (H_2): 1.3113 bitów/słowo
Stosunek H_1/H_0 (znaki): 0.7510

Navaho (norm_wiki_nv.txt):

Entropia znaków (H_0): 3.8749 bitów/znak
Entropia słów (H_0): 9.1540 bitów/słowo
Entropia warunkowa znaków (H_1): 2.9473 bitów/znak
Entropia warunkowa znaków (H_2): 2.3676 bitów/znak
Entropia warunkowa słów (H_1): 3.8639 bitów/słowo
Entropia warunkowa słów (H_2): 1.7188 bitów/słowo
Stosunek H_1/H_0 (znaki): 0.7606

Analiza tych wyników pozwala na zaobserwowanie kilku interesujących prawidłowości:

1. **Entropia znaków (H_0)** dla wszystkich badanych języków naturalnych waha się w przedziale od około 3.9 do 4.3 bitów/znak. Jest to dość wąski zakres, co sugeruje, że entropia bezwarunkowa znaków jest podobna dla różnych języków naturalnych, niezależnie od rodziny językowej.

Wartości te są znacznie niższe niż teoretyczne maksimum dla alfabetu łacińskiego, które wynosi około 4.9 bitów/znak (przy równomiernym rozkładzie 26 liter, 10 cyfr i spacji). Oznacza to, że w językach naturalnych niektóre znaki występują znacznie częściej niż inne, co jest zgodne z intuicją (np. w języku polskim litera 'a' występuje znacznie częściej niż 'x').

2. **Entropia słów (H_0)** jest znacznie wyższa, wynosząc od około 8 do 14 bitów/słowo. Wynika to z faktu, że słowa mają znacznie więcej możliwych wartości niż pojedyncze znaki.

Interesujące jest, że entropia słów dla języka estońskiego (13.7462 bitów/słowo) jest znacznie wyższa niż dla innych języków. Może to wynikać z bogatej morfologii języka estońskiego, w którym występuje 14 przypadków gramatycznych i złożony system tworzenia form wyrazów, co prowadzi do dużej różnorodności form słów.

Z kolei język haitański ma najniższą entropię słów (8.1669 bitów/słowo), co może wynikać z jego stosunkowo prostej struktury leksykalnej, typowej dla języków kreolskich.

3. **Entropia warunkowa znaków (H_1)** jest wyraźnie niższa niż entropia bezwarunkowa, co wskazuje na istnienie statystycznych zależności między sąsiednimi znakami w tekście. Dla wszystkich badanych języków entropia warunkowa pierwszego rzędu wynosi od około 2.9 do 3.5 bitów/znak.

Największa redukcja entropii w porównaniu z entropią bezwarunkową występuje dla języka haitańskiego (z 4.1464 do 3.1139 bitów/znak, redukcja o około 25%) i języka navaho (z 3.8749 do 2.9473 bitów/znak, redukcja o około 24%). Może to sugerować, że te języki mają bardziej przewidywalne sekwencje znaków.

4. **Entropia warunkowa znaków (H2)** jest jeszcze niższa, co pokazuje, że znajomość dwóch poprzednich znaków pozwala jeszcze lepiej przewidzieć następny znak. Największa redukcja w porównaniu z entropią warunkową pierwszego rzędu występuje dla języka haitańskiego (z 3.1139 do 2.2735 bitów/znak, redukcja o około 27%).
5. **Stosunek H_1/H_0 (znaki)** dla badanych języków naturalnych wynosi od około 0.75 do 0.84. Ta wartość jest kluczowym wskaźnikiem do rozpoznawania języków naturalnych.

Najniższy stosunek ma język haitański (0.7510), a najwyższy - język estoński (0.8410). Wyższy stosunek dla języka estońskiego może wynikać z jego struktury fonetycznej i ortograficznej, która może być mniej przewidywalna niż w innych badanych językach.

4.2 Klasyfikacja próbek testowych

Na podstawie analizy języków referencyjnych ustalono próg klasyfikacji wynoszący 0.8. Próbki testowe zostały sklasyfikowane następująco:

=== Klasyfikacja plików sample ===

Ustalony próg klasyfikacji: 0.8000

sample0.txt:

Entropia znaków (H_0): 4.2730 bitów/znak

Entropia warunkowa znaków (H_1): 2.9159 bitów/znak

Stosunek H_1/H_0 (znaki): 0.6824

Klasyfikacja: JĘZYK NATURALNY

Uzasadnienie: Stosunek entropii warunkowej do bezwarunkowej (0.6824) jest poniżej pr

sample1.txt:

Entropia znaków (H_0): 4.1270 bitów/znak

Entropia warunkowa znaków (H_1): 3.2392 bitów/znak

Stosunek H_1/H_0 (znaki): 0.7849

Klasyfikacja: JĘZYK NATURALNY

Uzasadnienie: Stosunek entropii warunkowej do bezwarunkowej (0.7849) jest poniżej pr

sample2.txt:

Entropia znaków (H_0): 3.9933 bitów/znak

Entropia warunkowa znaków (H_1): 3.0504 bitów/znak

Stosunek H_1/H_0 (znaki): 0.7639

Klasyfikacja: JĘZYK NATURALNY

Uzasadnienie: Stosunek entropii warunkowej do bezwarunkowej (0.7639) jest poniżej pr

sample3.txt:

Entropia znaków (H_0): 3.9303 bitów/znak

Entropia warunkowa znaków (H_1): 3.1845 bitów/znak

Stosunek H_1/H_0 (znaki): 0.8102

Klasyfikacja: TEKST LOSOWY/SZTUCZNY

Uzasadnienie: Stosunek entropii warunkowej do bezwarunkowej (0.8102) jest powyżej pr

sample4.txt:

Entropia znaków (H_0): 4.2538 bitów/znak

Entropia warunkowa znaków (H_1): 4.2291 bitów/znak

Stosunek H_1/H_0 (znaki): 0.9942

Klasyfikacja: TEKST LOSOWY/SZTUCZNY

Uzasadnienie: Stosunek entropii warunkowej do bezwarunkowej (0.9942) jest powyżej p

sample5.txt:

Entropia znaków (H_0): 4.4417 bitów/znak

Entropia warunkowa znaków (H_1): 3.5231 bitów/znak

Stosunek H_1/H_0 (znaki): 0.7932

Klasyfikacja: JĘZYK NATURALNY

Uzasadnienie: Stosunek entropii warunkowej do bezwarunkowej (0.7932) jest poniżej p

Szczegółowa analiza każdej z próbek:

1. **sample0.txt:** Próbką ta została sklasyfikowana jako język naturalny z bardzo niskim stosunkiem H_1/H_0 (0.6824). Jest to wartość niższa niż dla wszystkich badanych języków referencyjnych, co sugeruje, że tekst ten może zawierać bardzo regularne i przewidywalne sekwencje znaków. Może to być tekst w języku o wysokiej regularności statystycznej lub tekst, który zawiera powtarzające się frazy.
2. **sample1.txt:** Ta próbka również została sklasyfikowana jako język naturalny, ze stosunkiem H_1/H_0 wynoszącym 0.7849. Jest to wartość typowa dla języków naturalnych, porównywalna z wartościami dla esperanto (0.7997) czy haitańskiego (0.7510).
3. **sample2.txt:** Kolejna próbka sklasyfikowana jako język naturalny, ze stosunkiem H_1/H_0 wynoszącym 0.7639. Wartość ta jest bliska wartości dla języka navaho (0.7606), co może sugerować podobne właściwości statystyczne.
4. **sample3.txt:** Ta próbka została sklasyfikowana jako tekst losowy/sztuczny, ponieważ stosunek H_1/H_0 (0.8102) przekracza przyjęty próg 0.8. Jednak wartość ta jest bardzo bliska progowi i niewiele większa niż wartość dla języka angielskiego (0.8201) czy łacińskiego (0.8160). Może to oznaczać, że tekst ten ma pewne cechy języka naturalnego, ale z jakiegoś powodu (np. większa losowość sekwencji znaków) został sklasyfikowany jako sztuczny.
5. **sample4.txt:** Ta próbka została jednoznacznie sklasyfikowana jako tekst losowy/sztuczny, ze stosunkiem H_1/H_0 wynoszącym 0.9942. Jest to wartość bardzo bliska 1.0, co sugeruje, że znajomość poprzedniego znaku praktycznie nie pomaga w przewidywaniu następnego znaku. Taka wartość jest typowa dla tekstów generowanych losowo lub szyfrowanych.
6. **sample5.txt:** Ostatnia próbka została sklasyfikowana jako język naturalny, ze stosunkiem H_1/H_0 wynoszącym 0.7932. Jest to wartość zbliżona do wartości dla esperanto (0.7997), co może sugerować podobne właściwości statystyczne.

4.3 Interpretacja wyników

Obserwowane wartości entropii i ich stosunków można interpretować w kontekście teorii informacji i właściwości statystycznych języków naturalnych:

1. **Niższe wartości entropii warunkowej** w porównaniu z entropią bezwarunkową wskazują na istnienie redundancji w językach naturalnych. Ta redundancja wynika z reguł gramatycznych, fonetycznych i semantycznych, które ograniczają zbiór możliwych sekwencji znaków.

W praktyce oznacza to, że języki naturalne nie wykorzystują w pełni potencjalnej pojemności informacyjnej alfabetu. Gdyby wszystkie sekwencje znaków były równie prawdopodobne, entropia warunkowa byłaby równa entropii bezwarunkowej. Jednak w językach naturalnych niektóre sekwencje (np. 'th' w języku angielskim, 'sz' w języku polskim) występują znacznie częściej niż inne (np. 'xz'), co prowadzi do niższej entropii warunkowej.

2. **Stosunek entropii H_1/H_0 poniżej 0.8** sugeruje, że znajomość poprzedniego znaku zmniejsza niepewność co do następnego znaku o co najmniej 20%. Jest to dość znacząca redukcja niepewności, która w tekstach losowych praktycznie nie występuje.

Wartość tę można interpretować jako miarę 'przewidywalności' języka. Im niższy stosunek, tym bardziej przewidywalne są sekwencje znaków w danym języku. W naszym badaniu najniższy stosunek ma język haitański (0.7510), który może być uznany za najbardziej przewidywalny pod względem sekwencji znaków.

3. Interesująca jest obserwacja, że **różne języki naturalne mają podobne wartości stosunku entropii**, mimo różnic w entropii bezwarunkowej. Sugeruje to, że podstawowe właściwości statystyczne języków naturalnych są uniwersalne, niezależnie od konkretnego języka.

Ta uniwersalność może wynikać z podstawowych właściwości ludzkiej komunikacji, która dąży do równowagi między efektywnością przekazu a redundancją zapewniającą odporność na błędy. Zbyt wysoka entropia (brak przewidywalności) utrudniałaby komunikację, gdyż każdy błąd w przekazie miałby duży wpływ na zrozumienie. Z kolei zbyt niska entropia (wysoka przewidywalność) oznaczałaby, że język jest nieefektywny informacyjnie, przekazując mniej informacji na jednostkę tekstu.

4. **Entropia warunkowa drugiego rzędu** jest jeszcze niższa niż entropia warunkowa pierwszego rzędu, co pokazuje korzyści z uwzględnienia dłuższego kontekstu przy przewidywaniu następnego znaku. W praktycznych zastosowaniach, takich jak kompresja tekstu czy modelowanie języka, wykorzystuje się często konteksty o długości kilku do kilkunastu znaków, co pozwala na jeszcze lepsze odwzorowanie statystycznych właściwości języka.

Dla badanych języków redukcja entropii między H_1 a H_2 waha się od około 10% do 27%, co pokazuje, że drugi znak kontekstu nadal dostarcza istotnych informacji o prawdopodobieństwie następnego znaku. Jest to zgodne z intuicją językową - np. w języku polskim sekwencja 'sz' ma zupełnie inne prawdopodobieństwa wystąpienia następnego znaku niż sekwencja 'st'.

5. **Entropia słów** i jej redukcja w modelach warunkowych pokazuje, że prawidłowości statystyczne występują nie tylko na poziomie znaków, ale także na poziomie słów. Wysoka entropia słów (od 8 do 14 bitów/słowo) odzwierciedla dużą różnorodność słownictwa w językach naturalnych.

Interesujące jest, że redukcja entropii słów przy przejściu od modelu zerowego rzędu do pierwszego rzędu jest bardzo znacząca (od około 40% do 60%). Oznacza to, że znajomość poprzedniego słowa jest bardzo pomocna w przewidywaniu następnego słowa, co wynika z gramatycznych i semantycznych ograniczeń języka.

4.4 Analiza poszczególnych próbek

Warto dokładniej przeanalizować wyniki klasyfikacji próbek, aby lepiej zrozumieć działanie metody:

1. **sample0.txt** (stosunek $H_1/H_0 = 0.6824$): Bardzo niski stosunek entropii warunkowej do bezwarunkowej świadczy o wysokiej przewidywalności sekwencji znaków. Tekst ten został jednoznacznie sklasyfikowany jako język naturalny. Wartość 0.6824 jest niższa niż dla wszystkich badanych języków referencyjnych, co może sugerować, że tekst ten jest szczególnie regularny, zawiera powtarzające się frazy lub jest napisany w stylu, który sprzyja regularności (np. tekst formalny, techniczny, z ograniczonym słownictwem).
2. **sample1.txt** (stosunek $H_1/H_0 = 0.7849$): Stosunek entropii wskazuje na tekst w języku naturalnym. Wartość 0.7849 jest zbliżona do wartości dla esperanto (0.7997), co jest interesujące, ponieważ esperanto jest sztucznym językiem zaprojektowanym z myślą o regularności i prostocie. Można przypuszczać, że próbka ta może zawierać tekst o dość regularnej strukturze.
3. **sample2.txt** (stosunek $H_1/H_0 = 0.7639$): Kolejna próbka sklasyfikowana jako język naturalny, z wartością stosunku entropii zbliżoną do języka navaho (0.7606). Ponieważ navaho charakteryzuje się dość regularną strukturą fonetyczną i morfologiczną, można przypuszczać, że próbka ta również może zawierać tekst o wyraźnych prawidłowościach.
4. **sample3.txt** (stosunek $H_1/H_0 = 0.8102$): Ta próbka została sklasyfikowana jako tekst losowy/sztuczny, jednak stosunek entropii jest tylko nieznacznie powyżej progu 0.8. Wartość ta jest porównywalna z wartością dla języka angielskiego (0.8201), co sugeruje, że może to być język naturalny o nieco mniejszej przewidywalności sekwencji znaków niż większość badanych języków referencyjnych. Możliwe, że jest to język o złożonej fonologii lub tekst zawierający wiele terminów technicznych, co zmniejsza przewidywalność sekwencji.
5. **sample4.txt** (stosunek $H_1/H_0 = 0.9942$): Bardzo wysoki stosunek entropii, bliski 1.0, jednoznacznie klasyfikuje tę próbkę jako tekst losowy lub sztuczny. Wartość 0.9942 oznacza, że znajomość poprzedniego znaku praktycznie nie pomaga w przewidywaniu następnego znaku, co jest charakterystyczne dla tekstów generowanych losowo lub szyfrowanych.

Szczególne interesujące jest to, że entropia warunkowa (4.2291 bitów/znak) jest prawie równa entropii bezwarunkowej (4.2538 bitów/znak). Entropia bezwarunkowa o wartości około 4.25 bitów/znak jest typowa dla języków naturalnych, ale w połączeniu z prawie identyczną entropią warunkową sugeruje, że próbka ta może być tekstem w języku naturalnym, który został poddany jakiejś formie szyfrowania lub permutacji znaków, która zachowuje rozkład częstości znaków, ale niszczy zależności statystyczne między sąsiednimi znakami.

6. **sample5.txt** (stosunek $H_1/H_0 = 0.7932$): Ta próbka została sklasyfikowana jako język naturalny, ze stosunkiem entropii zbliżonym do progu 0.8, ale wciąż poniżej niego. Wartość 0.7932 jest bardzo bliska wartości dla esperanto (0.7997), co może sugerować podobne właściwości statystyczne.

Warto zauważyć, że entropia bezwarunkowa dla tej próbki (4.4417 bitów/znak) jest najwyższa wśród wszystkich analizowanych tekstów, co może wskazywać na bardziej równomierny rozkład częstości znaków niż w typowych językach naturalnych. Mimo to, wyraźna redukcja entropii w modelu warunkowym (do 3.5231 bitów/znak) świadczy o istnieniu znaczących zależności statystycznych między sąsiednimi znakami, charakterystycznych dla języków naturalnych.

5 Wnioski

Przeprowadzona analiza entropijna pokazuje, że:

1. Języki naturalne wykazują wyraźne prawidłowości statystyczne, które można wykryć poprzez porównanie entropii bezwarunkowej i warunkowej. Te prawidłowości są uniwersalne dla różnych języków, niezależnie od rodziny językowej czy używanego alfabetu.
2. Stosunek entropii warunkowej pierwszego rzędu do entropii bezwarunkowej jest skutecznym wskaźnikiem do rozpoznawania tekstów w językach naturalnych i odróżniania ich od tekstów losowych. Dla badanych języków naturalnych stosunek ten wynosi od około 0.75 do 0.84, co pozwala przyjąć wartość 0.8 jako rozsądny próg klasyfikacji.
3. Entropia warunkowa drugiego rzędu jest jeszcze niższa niż entropia warunkowa pierwszego rzędu, co sugeruje, że uwzględnienie dłuższego kontekstu poprawia przewidywalność następnego znaku. W praktycznych zastosowaniach, takich jak kompresja tekstu czy modelowanie języka, warto uwzględniać dłuższy kontekst.
4. Różne języki naturalne, mimo różnic w entropii bezwarunkowej, mają podobne wartości stosunku entropii warunkowej do bezwarunkowej. Sugeruje to, że wszystkie języki naturalne utrzymują podobną równowagę między efektywnością przekazu a redundancją zapewniającą odporność na błędy.
5. Teksty losowe lub sztuczne, takie jak próbka sample4.txt, charakteryzują się stosunkiem entropii warunkowej do bezwarunkowej bliskim 1.0, co wskazuje na brak przewidywalności sekwencji znaków.
6. Metoda entropijna jest skuteczna w klasyfikacji tekstów jako naturalne lub losowe, co może mieć zastosowanie w różnych dziedzinach, takich jak rozpoznawanie języka, ocena jakości tłumaczenia maszynowego, czy wykrywanie tekstów generowanych automatycznie.

Przedstawiona metoda jest przykładem aplikacji teorii informacji do problemów przetwarzania języka naturalnego. Jej zaletą jest prostota implementacji i interpretacji, a także niezależność od konkretnego języka lub alfabetu. Skuteczność metody w klasyfikacji próbek testowych potwierdza, że analiza entropijna jest użytecznym narzędziem w rozpoznawaniu języków naturalnych.

Progi entropii mogą być dostosowane do konkretnych zastosowań, w zależności od wymaganej czułości i specyficzności klasyfikacji. W naszym przypadku próg 0.8 okazał się skuteczny, ale dla innych zastosowań może być konieczne jego dostosowanie na podstawie większej liczby próbek referencyjnych.

Warto również zauważyć, że metoda ta ma swoje ograniczenia. Na przykład, teksty bardzo krótkie mogą nie zawierać wystarczającej liczby znaków, aby wiarygodnie oszacować entropię. Ponadto, teksty generowane przez zaawansowane modele języka, które odwzorowują statystyczne właściwości języków naturalnych, mogą być trudne do odróżnienia od prawdziwych tekstów w językach naturalnych.

Niemniej jednak, dla wielu zastosowań praktycznych, metoda entropijna oferuje dobry kompromis między prostotą a skutecznością, pozwalając na szybką i skuteczną klasyfikację tekstów bez konieczności stosowania bardziej złożonych technik przetwarzania języka naturalnego.